

| 2026-02-04

| Основные понятия машинного обучения

Машинное обучение — совокупность методов обработки информации таким образом, чтобы на основе набора задач выработать методику решения задач данного класса без применения традиционных алгоритмов.

Иными словами, машинное обучение **оценивает** определенные свойства входной информации для того, чтобы выработать механизм решения какой-либо задачи на основе уже сделанных решений.

Т.о. производится оценка, как те или иные свойства, характеристики, описывающие некоторое исходное состояние, сказались на результате решения некоторой иной задачи. Процедура «обучения» сводится к тому, чтобы максимизировать вес свойств, положительно сказавшихся на результате в прошлом, и минимизировать вес свойств, отрицательно влиявших на результат в предыдущих задачах.

Главной отличительной чертой машинного обучения от традиционных алгоритмов является отсутствие прямого метода решения задачи. Модель машинного обучения всегда обобщает множество решений сходных задач, вырабатывая более универсальный подход: при неизвестных входных данных обобщенное решение позволит получить адекватный ответ.

В современном понимании машинное обучение — обучение по прецедентам (обучение по примерам), которое ищет эмпирические закономерности во входных данных. На основе положительных (приведших к решению задачи) и отрицательных (приведших к провалу решения) примеров модель последовательно изменяет внутренние коэффициенты (веса) для каждого из входных параметров так, чтобы характеристики, имеющие большее влияние в положительных примерах, всегда получали приоритет над характеристиками, приведшими к провалу решения задачи.

≡ Пример

Есть завод. Есть 50 установок, потребляющих электроэнергию. Нужно предсказать прогноз потребления электроэнергии по времени работы указанных установок еженедельно.

1. Нужно составить примеры: фактическое время работы в течение недели каждой из установок и фактическое общее энергопотребление за неделю
2. Нужно учесть, что на энергопотребление могут влиять внешние факторы: например, время года, температура окружающей среды, график производства
3. Исходя из этого, нужно рассмотреть варианты увеличения примеров с точки зрения параметров, которые модель должна учитывать

4. Далее приступить к обучению модели: необходимо подобрать такие веса, чтобы время работы каждой установки, а также даты, в которые установка работала, вместе с другими учтенными факторами приводили к числу, которое максимально близко к исходному фактическому энергопотреблению в каждом примере

Как решить:

- XGBoost или LightGBM для табличных данных
- ИЛИ LSTM или Transformer-архитектура для временных рядов (если есть долгосрочные зависимости или сложные паттерны потребления)
- После обязательно постоянное дообучение модели на новых данных для адаптации к изменениям в производственном процессе

| Виды машинного обучения

| Обучение с учителем (Supervised Learning)

Наиболее распространенная категория в рамках моделей машинного обучения. Для каждого прецедента задается пара «состояние, требуемый результат».

Цель обучения с учителем — найти такую функцию, которая бы отображала максимально точно входные данные на выходные.

Т.е. необходимо найти такую $F()$, чтобы для максимального числа прецедентов в множестве состояний X были соответствия в множестве результатов Y .

$$Y = F(X)$$

| Классическое машинное обучение с учителем

- **Линейная регрессия**: для предсказания непрерывных значений
- **Логистическая регрессия**: для бинарной и мультиклассовой классификации
- **Деревья решений** и **случайный лес (Random Forest)**: для классификации и регрессии
- **Градиентный бустинг**: для табличных данных
- **Метод k -ближайших соседей (k-NN)**: для классификации и регрессии
- **Машины опорных векторов (SVM)**: для классификации с нелинейными границами
- **Наивный Байес**: вероятностный классификатор

| Глубокое обучение (Deep Learning) с учителем

- **Полносвязные нейронные сети (Feedforward NN)**: базовая архитектура

- **Сверточные нейронные сети (CNN):** для задач компьютерного зрения, обработки изображений
- **Рекуррентные сети (RNN, LSTM, GRU):** для временных рядов и последовательностей
- **Трансформеры:** универсальная архитектура для последовательностей

Типы задач

Множество задач, решаемых с помощью таких моделей, можно свести к двум большим категориям:

1. **Задачи классификации** — на выходе должна быть некоторая категория («здоров/болен», «шелти/колли/корги/немецкая овчарка», «брак/норма»)
2. **Задачи регрессии** — на выходе должно быть число (энергопотребление в ваттах, прогноз температуры в градусах Цельсия, сумма убытка или прибыли в рублях, максимальный вес груза в кг и т.п.)


Обучение без учителя (Unsupervised Learning)

Модели дается только множество состояний (что избавляет от необходимости разметки входных данных). Задачей такого обучения является выявление закономерности путем самоорганизации.

В рамках обучения без учителя решается задача кластеризации — разбиения неупорядоченного множества объектов на подгруппы в соответствии с их наблюдаемыми свойствами.

Алгоритмы кластеризации

- **Иерархическая кластеризация:** построение дерева кластеров





- **Метод k -средних (k-means)**: разбиение на k кластеров с минимизацией внутрикластерной дисперсии
- **DBSCAN**: кластеризация на основе плотности
- **Спектральная кластеризация**: на основе собственных векторов матрицы смежности


| Методы снижения размерности

- **Метод главных компонент (PCA)**: линейное преобразование в пространство с меньшей размерностью
- **Стохастическое вложение соседей с t-распределением (t-SNE)**: нелинейное снижение размерности для визуализации
- **Uniform Manifold Approximation and Projection (UMAP)**: современная альтернатива t-SNE, быстрее и лучше сохраняет глобальную структуру
- **Автоэнкодеры (Autoencoders)**: нейронные сети для сжатия и восстановления данных
- **Вариационные автоэнкодеры (VAE)**: генеративные нейросетевые модели для снижения размерности

| Другие методы

- **Самоорганизующиеся карты Кохонена (SOM)**: нейросетевой метод для визуализации и кластеризации многомерных данных





- **Контрастное обучение (Contrastive Learning):** обучение представлений через сравнение похожих и непохожих примеров
- **Generative Adversarial Networks (GAN):** генерация новых данных через соревнование генератора и дискриминатора

Обучение без учителя за счет выявления значимых признаков для отдельных категорий внутри исходных данных позволяет использовать такие модели для снижения размерности данных, обнаружения аномалий и предобработки данных для последующего обучения с учителем.

Обучение с частичным привлечением учителя (Semi-supervised Learning)

Часть входных данных размечена, как в случае с обучением с учителем, а часть — является неразмеченной. При этом соотношение размеченных и неразмеченных данных делается в пользу неразмеченных.

☰ Пример

В ходе курса решается и разбирается с преподавателем 10 задач. При этом на зачет выносятся 30 задач, схожих с уже решенными, но не являющихся дословными их повторениями. Готовых ответов к этим 30 задачам нет.

Основным преимуществом является повышение точности относительно обучения без учителя при меньших затратах на разметку по сравнению с полным обучением с учителем. Применяется в тех же областях, где и обучение без учителя.

| Обучение с подкреплением (Reinforcement Learning, RL)

В рамках обучения с подкреплением рассматривается некоторый **агент**, который имеет **цель** и может предпринимать **действия**.

При этом в ответ на действия он получает **сигналы** (обратную связь): если действия ведут к цели, эти сигналы положительные («пряник», вознаграждение, награда), если препятствуют достижению цели, то сигналы будут отрицательными («кнут», штраф, наказание).

Обучение достигается за счет максимизации агентом получаемой награды и минимизации наказания.

При этом изначально агент не знает ничего о **среде**, в которой он выполняет действия. Задача агента — выработать такой набор действий, чтобы вне зависимости от конфигурации среды он достигал бы цели максимальное количество раз.

| Примеры применения RL

RL применяется (например):

- **Управление роботами:** обучение роботов выполнять сложные задачи на основе базового набора доступных действий
- **Оптимизация производственных процессов:** поиск оптимальных режимов работы оборудования
- **Прогнозирование технического обслуживания:** принятие решений о техническом обслуживании (максимум работы с минимумом простоев)

| Современное состояние машинного обучения

| Трансформеры (Transformers) и большие языковые модели (LLM)

Трансформеры — архитектура нейронных сетей, представленная в статье «Attention Is All You Need» (Vaswani et al., 2017), которая стала основой для большинства

современных моделей глубокого обучения

Ключевой особенностью является **механизм внимания (Attention Mechanism)**, что позволяет модели динамически фокусироваться на релевантных частях входных данных

| Варианты архитектуры

1. **Только энкодер:** *BERT, RoBERTa, Vision Transformer (ViT)*, применяются для классификации, анализа тональности, извлечения признаков, задач компьютерного зрения
2. **Только декодер:** *GPT-серия, LLaMA, Mistral*, задачи: генерация текста, диалоговые системы, генерация кода
3. **Энкодер-декодер:** *T5, BART, MarianMT*, задачи: машинный перевод, обобщение текста, преобразование текста

| Большие языковые модели

Большие языковые модели (LLM) — трансформеры с миллиардами параметров, обученные на огромных корпусах текстов.

Объем их датасетов позволяет им демонстрировать способности к zero-shot и few-shot обучению, т.е. решению новых задач без дополнительного обучения или с минимальным количеством примеров.

Ключевые характеристики LLM:

- **Контекстное окно:** количество токенов, которое модель может обработать за один раз (от 4 тысяч до 2 миллионов)
- **Параметры:** количество обучаемых весовых коэффициентов (7B, 32B и т.п. до 1.7T параметров)
- **Мультимодальность (у современных):** способность работать с текстом, изображениями, аудио, видео одновременно

| Лабораторная работа №1. Построение линейной регрессионной модели

| Задание

1. Предоставлен набор данных — наблюдения за погодой ([Weather in Szeged 2006-2016 | Kaggle](#))
2. Данные включают в себя: время, описание, тип осадков, температуру, ощущаемую температуру, влажность, скорость ветра, направление ветра, видимость, давление
3. Необходимо построить регрессионную модель, которая принимает на вход сведения о **влажности и температуре**, выдает **ощущаемую температуру**

4. Необходимо визуализировать данные и линию регрессии при помощи диаграммы рассеяния
5. Усложнить регрессионную модель, добавив к влажности параметр **скорости ветра**. На выходе дать **ощущаемую температуру**.
6. Визуализировать модель (3D-график или pairplot)
7. Написать консольный тестовый стенд, демонстрирующий предсказание ощущаемой температуры по температуре, влажности и по температуре, влажности и скорости ветра

| Методические указания

1. Использовать класс `DataFrame` из библиотеки **pandas**, проследить за корректными dtypes (типами данных)
2. Использовать класс `LinearRegression` из библиотеки **Scikit-learn**
3. При обучении модели использовать `train_test_split` из **Scikit-learn** для разделения на обучающую и тестовую выборки (рекомендуемое соотношение: 80% / 20% или 70% / 30%)
4. Использовать библиотеку **seaborn** при построении диаграмм рассеяния
5. Для интерактивных графиков можно использовать **plotly**
6. Для множественной регрессии: `scatter_3d` или `pairplot`
7. Рассчитайте метрики: **MAE** (Mean Absolute Error, средняя абсолютная ошибка), **RMSE** (Root Mean Squared Error, среднеквадратичная ошибка) и R^2 (**коэффициент детерминации**) — использовать функции из `sklearn.metrics`

| Полезные ссылки

1. **Scikit-learn** (<https://scikit-learn.org>) — документация и примеры
2. **Hugging Face** (<https://huggingface.co>) — модели, датасеты, tutoriales
3. **Papers with Code** (<https://paperswithcode.com>) — статьи + код реализации
4. **Kaggle** (<https://kaggle.com>) — соревнования, датасеты, ноутбуки

Рашка С., Мирджалили В. **Python и машинное обучение** (Machine Learning with PyTorch and Scikit-Learn)